

# **CIÈNCIA OBERTA: promoció, suport i avaluació**



## **Unitat 2 – Integritat, transparència i replicabilitat de la ciència**

**Sessió del dia 15 de Novembre de 2023**

# **Replicabilitat i reproductibilitat de la recerca**

*Tria una llicència CC. Et recomanem aquestes (per a facilitar la reutilització):*

**Oriol Pujol Vila**  
Universitat de Barcelona




# DISCLAIMER

Si creus en:

- (a) Tota la resta d'èssers humans són “zombies” filosòfics
- (b) tot l'univers es va crear fa 5 minuts i s'ha omplert de memories i evidències falses sobre un passat distant,
- (c) estàs estirat al llit somniant tot el que et succeeix ara mateix, o
- (d) creus que ets un cervell en un pot estimulat electroquímicament per a tenir tots els estats mentals que tens (aka Matrix).

ESCEPTICISME: NEGACIÓ DE LA POSIBILITAT D'OBTENIR CONEIXEMENT



PER QUÈ CREIEU  
QUE ÉS  
IMPORTANT LA  
REPRODUCIBILITAT  
DE LA RECERCA?



# LA RECERCA I LA CERCA DEL CONEIXEMENT





# EPISTEMOLOGIA


Coneixement: Creença Veritable Justicada (Edmund Gettier)



Creença (El meu món intern)



Percepció  
Introspecció  
Memòria  
Raonament  
Testimoni



Justificació

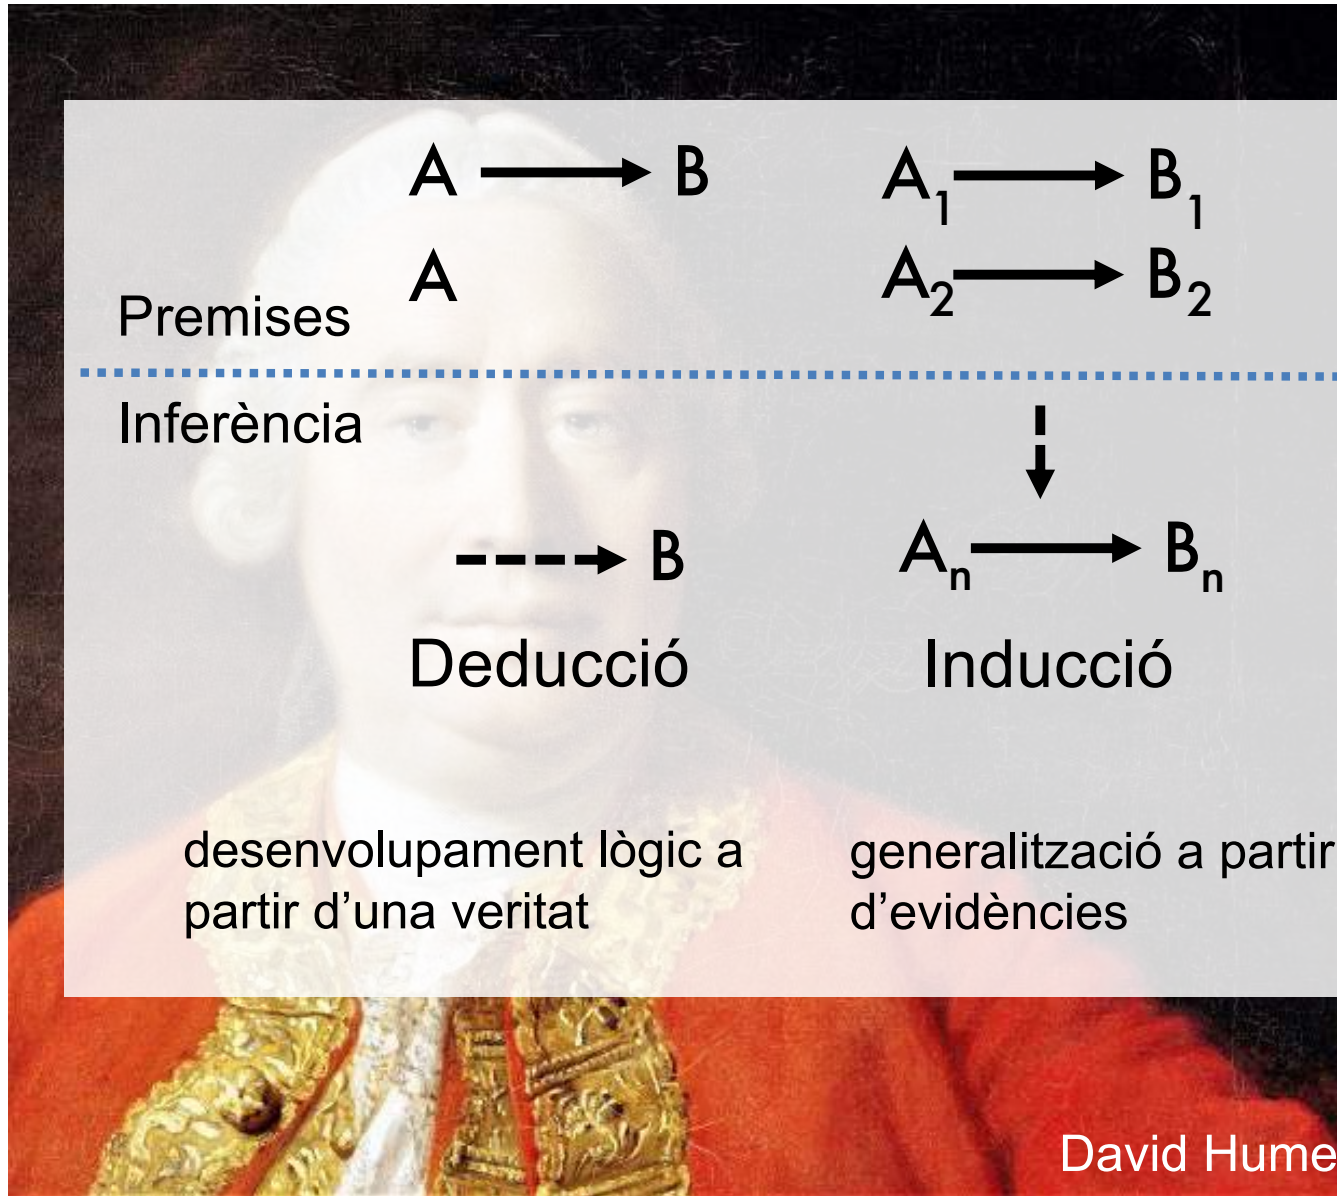


Veritable (El Món)

No pot ser falsificat, dubtat o corregit pels altres  
Independent de l'observador

# EPISTEMOLOGIA

## Inferència com a justificació



$A \longrightarrow B$   
 $B$

$A \leftarrow \text{---}$

Abducció

inferència a la millor explicació




# RECERCA

La creació de coneixement es planteja en tres possibilitats



Teòric



Experimental



Computacional

# INDUCCIÓ I L'INFERÈNCIA BAYESIANA

1. La meva creença es modifica en funció de les evidències.
2. Creença augmenta si la evidència suporta la creença.
3. Creença disminueix si la evidència no suporta la creença.

$$\text{CREENÇA} \mid \text{EVIDENCIA} = \text{modificador} * \text{CREENÇA}$$

Donat dos observadors amb la mateixa creença inicial (a priori) i la mateixa evidència arribaran a la mateixa conclusió/creença final (a posteriori)

Independent de la nostra creença a priori, si hi ha suficient evidència, el fenomen queda probabilísticament determinat.

Pierre-Simon Laplace




# UNA DE ROMANS

[https://github.com/oriolpujol/slides/blob/master/Reproducibility\\_Bayes.ipynb](https://github.com/oriolpujol/slides/blob/master/Reproducibility_Bayes.ipynb)







SI ÉS CONEIXEMENT,  
HA DE SER REPRODUIBLE!



# IDEES IMPORTANT

1. Calen evidències per crear coneixement.
2. Les evidències poden ser més observacions sota la mateixa hipòtesi
3. Són evidències, també, si es poden reproduir les conclusions amb noves observacions ben controlades.
4. Si quelcom no es replicable/reproducible només hi ha una evidència i per tant no es pot justificar i crear coneixement.
5. El mecanisme d'inferència inductiva es trans-disciplinar.
6. Si diversos grups de recerca treballen sota la mateixa pregunta es poden juntar evidències i donar suport a una hipòtesi.
7. Permet la reinterpretació de les evidències i la potencial correcció d'errors.

# EL “REPLIGATE”




## CONSEQÜÈNCIES SOCIALS

Pèrdua de temps,  
Pèrdua de diners,  
Pèrdua de credibilitat



# A QUÈ ES DEU?






QUÈ  
NECESSITEM  
PER FER  
RECERCA  
REPRODUIBLE?

---



# EL PASTÍS REPRODUIBLE



**Replicable** – es pot repetir?

(es poden tornar a recollir els ingredients i replicar les condicions per realitzar el pastís? Es poden obtenir resultats consistents per respondre la mateixa qüestió?)

**Reproducible** – parla de la validació del procés. S'arriben a les conclusions similars amb les mateixes dades i mètode?


## Què necessitem per fer el pastís reproducible?

# EL PASTÍS REPRODUIBLE



Ingredients: Els podem trovar?

Quantitats: Quina quantitat s'ha fet servir?



Procés: Tenim la recepta?



Entorn: Tenim les condicions per reproduir la cocció?



# RECERCA REPRODUIBLE

## Copying Machine Learning Classifiers

IRENE UNCETA<sup>1,2</sup>, JORDI NIN<sup>1,2</sup>, AND ORIOL PUJOL<sup>2</sup>

<sup>1</sup>Basics Data & Analytics, 08035 Barcelona, Spain  
<sup>2</sup>Department of Mathematics and Computer Science, Universitat de Barcelona, 08037 Barcelona, Spain  
Corresponding author: Irene Unceta (irene.unceta@ub.edu)

This work was supported in part by the Spanish Project OFICEN under Grant PID2019-105093GB-100, and in part by the AGAUR of the Generalitat de Catalunya through the Industrial PhD, under Grant 2017 DI 25.

**ABSTRACT** We study copying of machine learning classifiers, an agnostic technique to replicate the decision behavior of any classifier. We develop the theory behind the problem of copying, highlighting its properties, and propose a framework to copy the decision behavior of any classifier using no prior knowledge of its parameters or training data distribution. We validate this framework through extensive experiments using data from a series of well-known problems. To further validate this concept, we use three different use cases where desiderata such as interpretability, fairness or productivization constraints need to be addressed. Results show that copies can be exploited to enhance existing solutions and improve them adding new features and characteristics.

**INDEX TERMS** Applied machine learning, classification, copying, differential replication, fidelity.

### I. INTRODUCTION

In many every-day examples, performance of state-of-the-art machine learning is held back by operational constraints that appear along a system's life-cycle. Either the data or the models themselves are subject to privacy restrictions [1]–[3] or new specific regulations apply that require models to be self-explanatory [4]–[6] or fair with respect to sensitive data attributes [7]–[9]. Other issues include time or space limitations for deployment, and production bottlenecks in delivering certain models to the market [10]. To the best of our knowledge, these issues have been traditionally addressed by means of re-training tailored solutions. As a result, off-the-shelf machine learning techniques often yield only sub-optimal results or can only be exploited during a limited period of time.

Under such circumstances, training a new model may seem straightforward. However, a re-training is not always possible, nor advisable. This may be, for example, because production protocols require the maintenance of predictive performance over time, because the specifics of the model are unknown or even because the training data are no longer available. What is more, re-training is timely and often costly too, as it may require a non-negligible amount of human and material resources. Whatever the cause, the impossibility of re-training calls for new ways to address this situation.


The associate editor coordinating the review of this manuscript and approving it for publication was Yungang Li.

In this article we study copying, the problem of building a new model that replicates the decision behavior of another. The idea of approximating a model's decision boundary can be found in the literature under different topics, including model extraction [11], [12], knowledge distillation [13], [14], or adversarial learning [15], [16]. All these notions refer to scenarios where the knowledge acquired by one model is used to build another. Specifically, we here envisage the most agnostic scenario, where we make the minimum number of required assumptions about the amount of information available during the process. We assume access to the model is limited to a membership query interface. In addition and unlike previous articles, where the training data distribution is directly [13] or indirectly [14] known, we also assume the training data to be unknown or, simply, lost. Finally, we also assume the query interface to produce only hard predictions, as opposed to scenarios where rich information outputs can be used as soft targets for the new model [17], [18]. This scenario can be understood as a form of zero-knowledge distillation, where the decision behavior of a larger model is transferred to a simpler one in circumstances where no knowledge is assumed about the training data or the model internals. Effectively, this corresponds to an scenario where the larger model is a black-box and distillation is conducted in a data-free way.

In this context, we propose copying as a methodology to project the decision function learned by a model onto a new hypothesis space that enables the same decision behaviour,



**Ingredients:** Dades (detalls d'aquisició, disseny experimental, metadades, etc.)



**Recepta:** Decisions fetes (netejan, processant, recodificant, etc)

**Resultats** (clars i tant objectius com sigui possible)



**Entorn:** Eines i entorns (materials, programari, paquets, etc.)

# ACCÉS a tots aquests!!!!

# INGREDIENTS



Dades - Dades Obertes (diversos nivells d'obertura)

DADES CRUES sense preprocessar

- REPOSITORIS DE DADES PÚBLICS - BENCHMARKS
- REPOSITORES OPEN DATA


OpenData



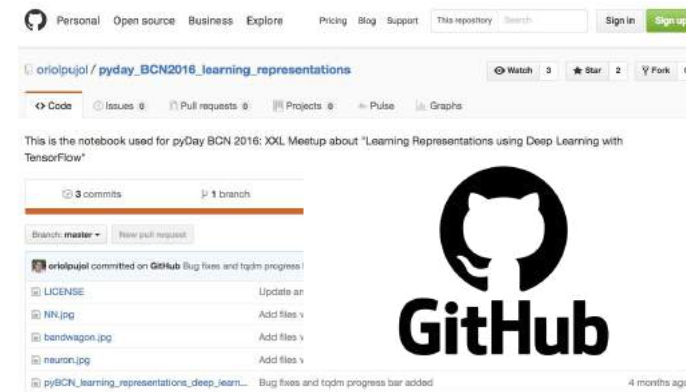
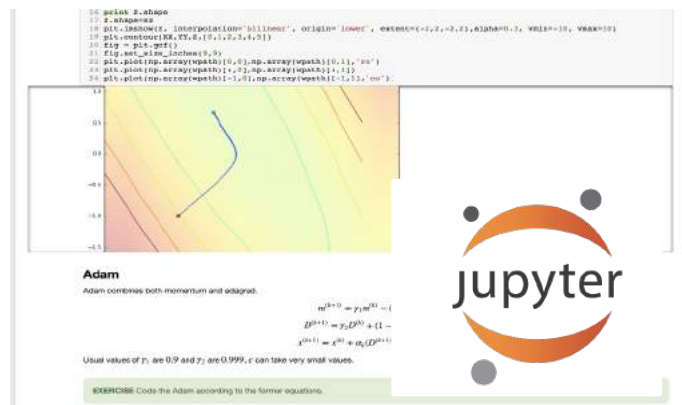
Most Popular Data Sets (hits since 2007)		
1189468:		<a href="#">Iris</a>
816286:		<a href="#">Adult</a>
621858:		<a href="#">Wine</a>
534408:		<a href="#">Car Evaluation</a>



# PROCÉS I RESULTATS



Decisions fetes (publicacions, codi, github, jupyter notebooks)  
Resultats (publicacions, metadades)



arXiv is a free distribution service and an open-access archive for 2,022,298 scholarly articles in the fields of physics, mathematics, computer science, quantitative biology, quantitative finance, statistics, electrical engineering and systems science, and economics. Materials on this site are not peer-reviewed by arXiv.

# ENTORN



Eines i entorns (entorn de treball – Docker)

**Contenidor:** Encapsulament del programari, totes les llibreries i dependències en una imatge que funciona sobre un Sistema Operatiu virtualitzat.

- Encapsulament de l'experiment (freeze)
- Transportabilitat (mínim espai)
- Interoperabilitat i reusabilitat (independent del sistema operatiu hoste)



# CONCLUSIONS

1. Recerca és més que una publicació
2. Al cor de la recerca es troba la reproduïbilitat... i això sempre involucra dades.
3. Però dades no són suficients... el codi, metadades, i descripció del procés.
4. Requeriment: **Accessibilitat**
5. Alfabetització sobre les dades i el seu tractament (programació?) són necessaries.

GRÀCIES!